**Pontificia Universidad Católica de Chile**

Facultad de Matemáticas

# Informe Final

Autores:

Francisca Sepúlveda, Alexander Pinto, Karina Armijo y Pía Mella

Segundo Semestre 2026

## Resumen ejecutivo

El presente estudio tiene como objetivo predecir el valor de las transacciones inmobiliarias residenciales en el departamento de Rhône (69), Francia, durante el período 2021–2023, utilizando la base de datos oficial *Demandes de valeurs foncières géolocalisées* (DVF). Para ello, se realiza un proceso de depuración y consolidación de los registros, seguido de la implementación y comparación de tres modelos predictivos: *Lasso*, Modelo Aditivo Generalizado (GAM) y *XGBoost*. La evaluación se desarrolla mediante una partición temporal, reservando el año 2023 para medir la capacidad predictiva de los modelos. Los resultados muestran que *XGBoost* presenta el mejor desempeño, alcanzando un MAE de 53,237, 81 € y un RMSE de 94,363, 37 €. Asimismo, se identifica que la superficie habitable y la ubicación geográfica son los atributos de mayor relevancia para las estimaciones. Sin embargo, se observan mayores errores en viviendas de alto valor y zonas con pocos antecedentes de compraventa. En conjunto, los resultados destacan la utilidad de los métodos de aprendizaje automático para estimar precios inmobiliarios, así como la importancia de considerar las características físicas y geográficas de las propiedades.


## 1. Introducción

El mercado inmobiliario constituye un ámbito de gran relevancia económica y social, ya que el valor de las propiedades influye directamente en las decisiones de compra, venta e inversión. En este contexto, comprender las características asociadas al precio de los inmuebles resulta fundamental para realizar estimaciones adecuadas y aportar información útil para la toma de decisiones. Entre los principales factores que pueden influir en su valor se encuentran las características físicas de las viviendas, como la superficie y el número de habitaciones, su ubicación geográfica y el período en que se realiza la transacción. Para abordar esta problemática, se utiliza la

base de datos Demandes de valeurs foncières géolocalisées (DVF), correspondiente al departamento de Rhône (69), ubicado en la región de Auvergne-Rhône-Alpes, Francia. La información comprende las transacciones inmobiliarias registradas entre los años 2021 y 2023. A partir de estos registros, se construye una base analítica que considera exclusivamente compraventas residenciales asociadas a un único inmueble principal, estableciendo cada transacción como unidad de observación. La variable de respuesta corresponde al valor de compraventa (`valeur_foncière`), expresado en euros. En este sentido, el objetivo del estudio consiste en identificar los

principales factores asociados al precio de las viviendas y comparar tres modelos estadísticos para predecir el valor de una transacción inmobiliaria residencial. Para ello, se evalúa su desempeño predictivo mediante distintas métricas, considerando la precisión de las estimaciones y su capacidad de generalización a nuevos datos. Finalmente, se analizan los resultados obtenidos, la sensibilidad de las predicciones y las principales limitaciones del estudio, con el propósito de identificar el modelo que proporcione estimaciones más precisas y consistentes.

## 2. Objetivo de trabajo

El objetivo de este informe es predecir el precio de los inmuebles ubicados en el departamento de Rhône (código 69), equivalente a una provincia en la división territorial francesa y perteneciente a la región de Auvernia-Ródano-Alpes, Francia, durante el período 2021–2023, utilizando la base de datos *Demandes de valeurs foncières* (DVF) géolocalisées. Para ello, se implementan tres modelos predictivos con enfoques metodológicos diferentes: regresión, modelos flexibles y métodos de ensamble.

# 3. Análisis de los datos

La base de datos utilizada corresponde a *Demandes de valeurs foncières géolocalisées* (DVF), que originalmente contiene 301.891 registros y 40 variables. Según su naturaleza, estas últimas se clasifican en 12 variables cuantitativas, de las cuales 10 son continuas y 2 discretas, y 28 variables cualitativas o categóricas. En conjunto, permiten caracterizar las transacciones inmobiliarias desde distintas dimensiones, considerando tanto las características de los inmuebles como sus atributos geográficos y temporales.

A partir de esta información, se establecen los principales elementos que delimitan el estudio, considerando la población de interés, la muestra inicial, la unidad de análisis y las variables utilizadas en la construcción de los modelos predictivos:

- **Población de estudio:** Corresponde al conjunto de transacciones inmobiliarias realizadas en el departamento de Rhône (código 69), Francia, durante el período 2021–2023.
- **Muestra:** Está constituida inicialmente por los 301.891 registros disponibles en la base de datos DVF, correspondientes al departamento de Rhône y al período 2021–2023. Estos registros se someten posteriormente a un proceso de selección y depuración para obtener la muestra definitiva del análisis.
- **Unidad de análisis:** Corresponde a cada operación de transacción inmobiliaria.
- **Variable respuesta:** Corresponde a `valeur_fonciere`, de naturaleza cuantitativa continua, que representa el valor monetario de cada transacción inmobiliaria, expresado en euros (€). En la base de datos original, esta variable presenta valores que oscilan entre 0 y 236.160.000 €. Constituye el objeto de predicción de los modelos estadísticos, cuyo propósito es estimar el precio de compraventa a partir de las características de los inmuebles y de la información disponible.
- **Predictores y disponibilidad de información:** La base de datos dispone de 39 variables explicativas, una vez excluida la variable respuesta. Estas permiten caracterizar las transacciones inmobiliarias desde cinco dimensiones: temporal y transaccional, espacial y geográfica, física e inmobiliaria, copropiedad y lotes, y uso de suelo. Su selección considera la relevancia de la información para explicar y predecir el precio de los inmuebles.
- **Procedencia de los datos:** Los datos provienen de la base oficial *Demandes de valeurs foncières géolocalisées* (DVF), elaborada por la Dirección General de Finanzas Públicas de Francia (DGFiP). Para este estudio se utiliza la edición archivada de diciembre de 2025, correspondiente al departamento de Rhône (69) y al período 2021–2023.

Una vez establecidos los elementos que delimitan el estudio, se presenta el procedimiento de selección y depuración de la base de datos. Este procedimiento permite identificar los criterios aplicados, las observaciones excluidas y las modificaciones realizadas a la base original hasta obtener la muestra final utilizada en la estimación y comparación de los tres modelos predictivos.

## 3.1. Depuración y limpieza de datos

Como primera etapa del proceso de depuración, se realiza una exploración y visualización de la base de datos con el propósito de comprender su estructura e identificar las características de los registros. En particular, se analiza la variable `id_mutation`, que corresponde al identificador único de cada transacción inmobiliaria. Sin embargo, se observa que un mismo identificador puede estar asociado a múltiples filas, debido a que una operación puede involucrar distintos tipos de inmuebles, los cuales se registran de manera separada mediante la variable `type_local`.

Esta última variable presenta cuatro categorías: *Dépendance*, *Appartement*, *Local industriel, commercial ou assimilé* y *Maison*. Por lo tanto, una misma transacción puede incluir una combinación de estas categorías, lo que implica que no todas las operaciones registradas corresponden exclusivamente a compraventas de viviendas residenciales.

En consecuencia, es necesario establecer qué se entiende por vivienda para efectos de este estudio. En este contexto, se considera como tal toda propiedad destinada al uso habitacional, cuya clasificación en la base de datos corresponde a una casa (*Maison*) o un departamento (*Appartement*). Por consiguiente, el análisis se limita a transacciones de carácter exclusivamente residencial, excluyendo aquellas que incorporan inmuebles de uso comercial, industrial o de servicios, así como las operaciones en las que no es posible identificar una vivienda edificada.

A partir de esta definición, se establecen los siguientes criterios de selección, aplicados sobre la variable `type_local` y el identificador `id_mutation`, con el propósito de obtener una muestra compuesta por transacciones residenciales comparables:

1. **Auditoría inicial de las combinaciones de inmuebles.** En primer lugar, se identifican y agrupan los tipos de inmuebles presentes en cada transacción, mediante el identificador `id_mutation`. Esto permite caracterizar las distintas composiciones de las operaciones inmobiliarias y distinguir entre aquellas que incluyen una única tipología de inmueble y aquellas que presentan combinaciones de viviendas y dependencias.

2. **Eliminación de registros duplicados.** Se eliminan las filas idénticas presentes en la base de datos original, con el objetivo de evitar la contabilización repetida de una misma observación y asegurar que la estructura de las transacciones se evalúe sobre registros únicos.

3. **Exclusión de transacciones con uso comercial o industrial.** Se descartan todas las operaciones que contienen al menos un inmueble clasificado como local industrial, comercial o asimilado. Este criterio permite excluir transacciones de uso mixto, cuyos precios pueden responder a características y dinámicas de mercado distintas de las correspondientes al sector residencial.

4. **Exclusión de transacciones con tipologías residenciales mixtas.** Se eliminan las operaciones que incluyen simultáneamente casas (*Maison*) y departamentos (*Appartement*). Esta decisión busca evitar transacciones cuyo precio total no puede atribuirse de manera directa a una única tipología de vivienda.

5. **Exclusión de transacciones con múltiples viviendas principales.** Se descartan las operaciones que contienen dos o más casas, o dos o más departamentos. Estas transacciones pueden corresponder a la venta conjunta de varias unidades inmobiliarias, por lo que el precio registrado en `valeur_fonciere` representa el valor agregado de la operación y no necesariamente el de una vivienda individual.

6. **Exclusión de transacciones sin vivienda principal identificable.** Se eliminan las operaciones compuestas exclusivamente por dependencias o bodegas, así como aquellas en las que la clasificación del inmueble se encuentra completamente ausente. También se excluyen las transacciones que combinan únicamente dependencias y registros sin clasificación. Con ello, se busca asegurar que cada operación seleccionada incluya una vivienda principal identificable.

7. **Depuración de terrenos con información incompleta.** Para las transacciones que presentan registros de terrenos sin una clasificación de tipo de inmueble, se examina la información relativa al uso o naturaleza del suelo. Se excluyen aquellas operaciones cuyos registros no contienen información en la variable `code_nature_culture` (tipo de cultivo del terreno), dado que la ausencia de esta clasificación impide caracterizar adecuadamente el terreno asociado a la transacción.

8. **Revisión y exclusión de casos con inconsistencias catastrales.** Finalmente, se realiza una revisión individual de las observaciones que presentan inconsistencias entre la superficie registrada y el tipo de inmueble. Como resultado de esta auditoría, se excluyen cinco transacciones cuyos registros presentan inconsistencias catastrales que no pueden resolverse a partir de la información disponible.

En conjunto, estos criterios permiten depurar progresivamente la base de datos, excluyendo operaciones que no se ajustan a la definición de vivienda de uso exclusivamente residencial o que presentan inconsistencias que impiden su adecuada caracterización. De esta manera, se obtiene una muestra más homogénea, en la que cada observación representa una transacción asociada a una única vivienda principal, ya sea una casa o un departamento.

## Consolidación de las transacciones y construcción de variables

Una vez aplicados los criterios de selección, se procede a consolidar la información a nivel de transacción, utilizando el identificador `id_mutation`. Este procedimiento permite transformar la base de datos original, en la que una misma operación puede estar representada por varias filas, en una estructura donde cada observación corresponde a una única transacción inmobiliaria.

Para ello, se agrupan los registros asociados a cada identificador y se construyen variables que resumen las principales características de la operación. Entre ellas se consideran la superficie habitable, el número de habitaciones, la cantidad de dependencias y las características de los terrenos asociados, además de conservar la información relativa al ¡precio de venta y la ubicación del inmueble. De esta manera, se obtiene una base consolidada que permite caracterizar cada transacción de forma individual y utilizarla posteriormente en la estimación de los modelos predictivos.

## Diagnóstico y tratamiento de valores faltantes

A partir de la base consolidada, denominada `df_modelamiento`, que contiene inicialmente 76.477 transacciones, se realiza un diagnóstico de los valores faltantes en las variables utilizadas para el modelamiento. Como resultado de esta revisión, se identifican dos situaciones que requieren tratamiento:

1. **Eliminación de observaciones con valores faltantes o inválidos en la variable respuesta.** Se identifican 23 transacciones cuyo precio de venta, registrado en `valeur_fonciere`, presenta un valor faltante o es menor o igual a cero. Dado que esta variable constituye la respuesta del estudio, estas observaciones se excluyen del análisis, ya que no cuentan con un valor válido que permita estimar o evaluar el precio de los inmuebles. Como resultado, la muestra se reduce a 76.454 transacciones.

2. **Imputación de valores faltantes en el número de habitaciones.** Se identifican dos observaciones con información faltante en las variables `piezas_max` y `piezas_sum`, correspondientes al número de habitaciones de los inmuebles residenciales. Para conservar estas transacciones, se realiza una imputación mediante la media observada, diferenciando según el tipo de vivienda (*Maison* o *Appartement*). De esta forma, a cada observación se le asigna la media correspondiente a su tipología residencial, redondeada al entero más cercano, dado que se trata de variables de conteo.

3. **Imputación de valores faltantes en latitud y longitud.** Se identificaron 1.242 observaciones con información faltante en las variables `latitude` y `longitude`. Para conservar estas transacciones, se realiza una imputación mediante la mediana observada, diferenciando según la comuna. De esta forma se preserva la localización macro-territorial sin distorsionar la estructura espacial por valores atípicos.

4. **Imputación de valores faltantes en el número de habitaciones.** Se identifican dos observaciones con información faltante en las variables `piezas_max` y `piezas_sum`, correspondientes al número de

habitaciones de los inmuebles residenciales. Para conservar estas transacciones, se realiza una imputación mediante la media observada, diferenciando según el tipo de vivienda (*Maison* o *Appartement*). De esta forma, a cada observación se le asigna la media correspondiente a su tipología residencial, redondeada al entero más cercano, dado que se trata de variables de conteo.

## Revisión de variables continuas y criterios de calidad inmobiliaria

Posteriormente, se examina la distribución y consistencia de las principales variables cuantitativas, con especial atención al precio de venta y a la superficie habitable. Para ello, se utilizan diagramas de caja (*boxplots*), representados mediante una escala logarítmica, con el propósito de facilitar la visualización de distribuciones asimétricas e identificar posibles observaciones extremas.

Adicionalmente, se construye una variable auxiliar denominada `precio_m2`, definida como el cociente entre el precio de venta y la superficie habitable:

$$\boxed{\texttt{precio_m2} = \frac{\texttt{valeur_fonciere}}{\texttt{surface_habitable}}}$$

Esta variable permite examinar la relación entre el valor de la transacción y la dimensión de la vivienda, facilitando la identificación de registros que presentan valores económicos o superficies potencialmente inconsistentes. A partir de esta revisión, se aplican los siguientes criterios adicionales de depuración:

1. **Exclusión de superficies habitables inferiores a 8 $\mathbf{m^2}$.** Se eliminan las transacciones cuya superficie habitable es inferior a 8 $m^2$, debido a que estos registros pueden corresponder a espacios de dimensiones reducidas o a posibles inconsistencias en la clasificación de la propiedad como vivienda principal. Este criterio permite establecer un umbral mínimo de superficie para las observaciones incluidas en el análisis.

2. **Selección de transacciones correspondientes a ventas.** Se conservan exclusivamente las operaciones cuya variable `nature_mutation` corresponde a la categoría *Vente*. De esta manera, se excluyen otros tipos de transferencias inmobiliarias, como permutas o adjudicaciones, cuyas condiciones de valoración pueden diferir de las de una compraventa convencional.

3. **Exclusión de transacciones con un precio por metro cuadrado inferior a 1.000 euros.** Finalmente, se excluyen las transacciones cuyo precio por metro cuadrado es inferior a 1.000 €/$m^2$, debido a que estos valores se encuentran considerablemente alejados de los precios observados en el mercado inmobiliario residencial y no representan valores económicamente plausibles para las viviendas analizadas. Por este motivo, se consideran registros inconsistentes y se eliminan de la muestra, con el propósito de evitar que distorsionen la estimación de los modelos predictivos.

Como resultado de estos procedimientos, se obtiene la base denominada `df_modelamiento_listo`, que reúne las transacciones que cumplen con los criterios de selección, disponibilidad de información y consistencia definidos para el estudio. Esta base constituye el conjunto de datos utilizado en las etapas posteriores de estimación y comparación de los tres modelos predictivos.

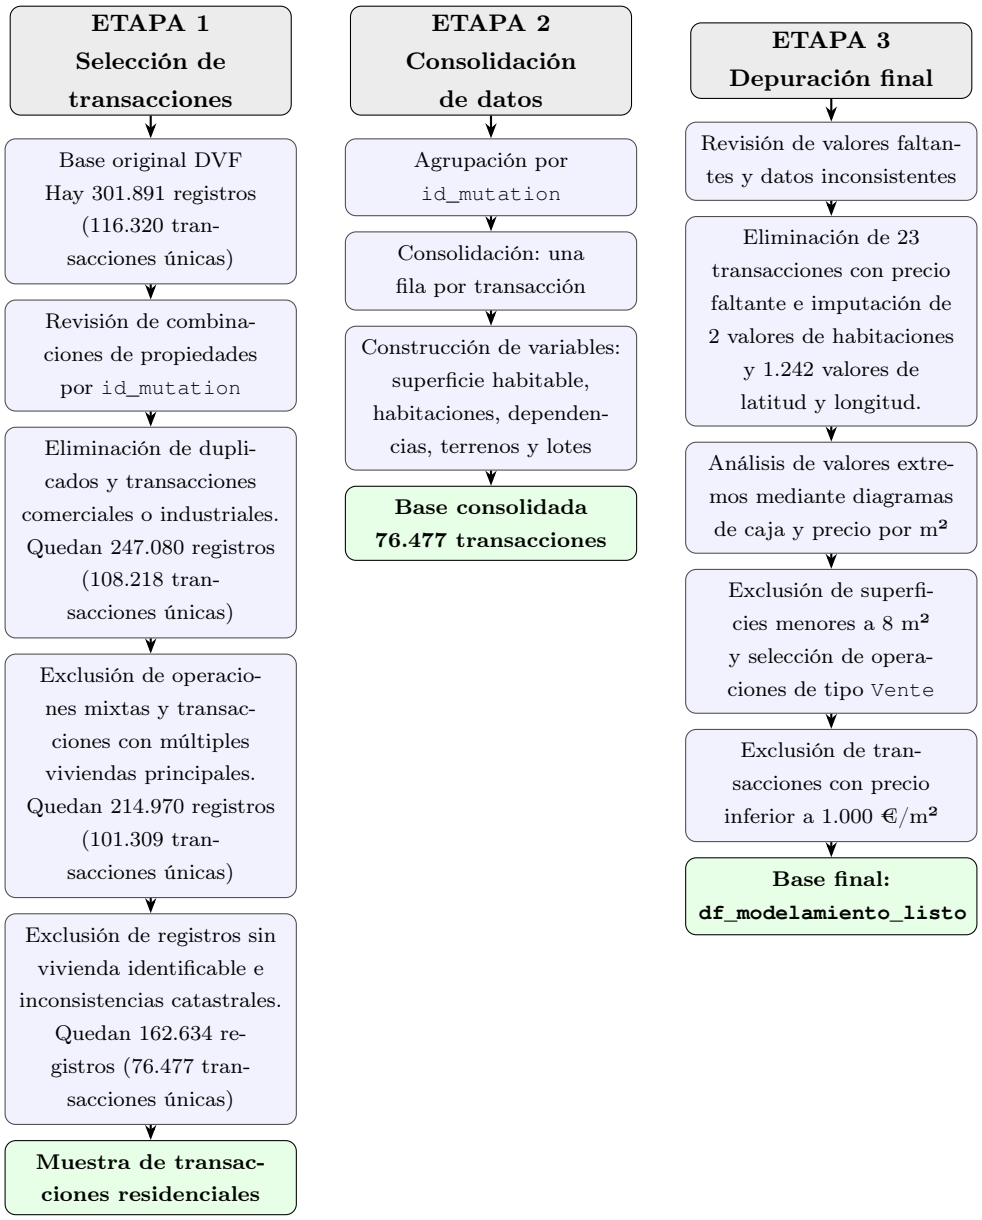



Figura 1: Etapas de selección, consolidación y depuración de la base de datos DVF.

# 4. Diseño de evaluación

## 4.1. Partición de la base de datos

Una vez finalizado el proceso de limpieza y depuración, se obtiene la base de datos que se utiliza para la construcción de los modelos predictivos. En esta etapa, resulta necesario dividir las observaciones en conjuntos destinados al entrenamiento, evaluación y prueba, con el propósito de medir la capacidad de los modelos para predecir los precios de las transacciones inmobiliarias.

Considerando que la base de datos comprende transacciones realizadas durante los años 2021, 2022 y 2023, se adopta un esquema de partición temporal. Este criterio permite respetar el orden cronológico de las observaciones y evaluar el desempeño de los modelos utilizando información de un período posterior al empleado durante su entrenamiento.

En particular, las transacciones correspondientes a los años 2021 y 2022 se destinan al conjunto de entrenamiento y validación (72 % y 28 % respectivamente), mientras que las observaciones del año 2023 se reservan para el

conjunto de prueba. De esta manera, los modelos se estiman utilizando información histórica y posteriormente se evalúa su capacidad predictiva frente a transacciones de un período que no ha sido utilizado durante el ajuste.

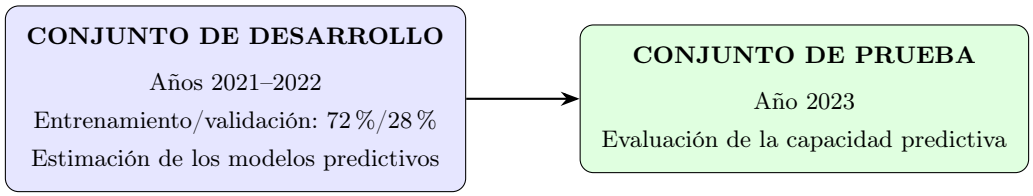



Figura 2: Esquema de partición temporal de la base de datos.

# 5. Métodos

Para la estimación del valor de las transacciones inmobiliarias, se consideran tres enfoques metodológicos complementarios: un modelo de regresión regularizada (Lasso), un modelo aditivo generalizado de patrones no lineales (GAM) y un método de ensamble basado en árboles de decisión (XGBoost).
Como decisión metodológica fundamental, la variable respuesta $Y$ = valeur_fonciere se transformó a escala logarítmica natural:

$$\text{log_valeur_fonciere} = \log(\text{valeur_fonciere})$$

Esta decisión se respalda empíricamente en la Figura 4. En la escala original en euros (panel izquierdo), la distribución de los precios de compraventa presenta una marcada asimetría positiva (sesgo a la derecha), caracterizada por una alta concentración de transacciones en valores medios y una cola derecha extendida correspondiente a inmuebles de alto valor. Al aplicar la transformación logarítmica $\log(Y)$ (panel derecho), la distribución se simetriza adopta una morfología unimodal y acampanada (bell-shaped), lo que permite:

Dado que los tres métodos se entrenan para predecir $\log(Y)$, las predicciones en escala logarítmica $\widehat{\log Y}$ se retransforman a la escala monetaria original mediante $\hat{Y} = \exp(\widehat{\log Y})$ para evaluar el desempeñado predictivo final en euros reales (MAE y RMSE).

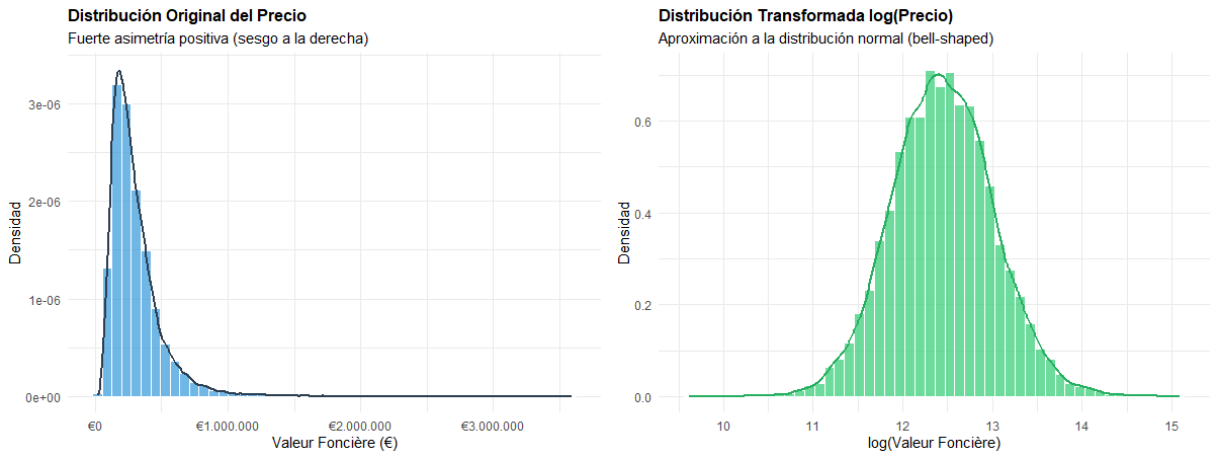



Figura 3: Comparativa de la distribución de del precio de las viviendas con y sin logaritmo.

## 5.1. Modelo de refrencia

Como punto de partida metodológico, se definió un modelo de referencia ($M_0$) consistente en predecir el valor logarítmico del suelo mediante la mediana observada según el tipo de propiedad (`type_local`: casa o departamento), estimada exclusivamente sobre el conjunto de entrenamiento (2021–2022). Este *benchmark* no utiliza

atributos físicos ni espaciales, permitiendo cuantificar la ganancia neta en precisión y reducción del error que aportan los procedimientos regularizados y no lineales ($M_1$, $M_2$ y $M_3$) bajo la misma estructura de validación insesgada.

## 5.2. Lasso

La regresión Lasso se implementa para evaluar un enfoque de regresión lineal penalizada. Este método permite abordar la alta dimensionalidad y la colinealidad potencial entre las características físicas, cuantitativas y geográficas de las propiedades mediante la incorporación de una penalización de norma $L_1$ sobre los coeficientes de regresión.

Para la formulación del modelo Lasso, la matriz de diseño $X$ se construyó excluyendo el identificador de transacción (id_mutation) y expandiendo las variables categóricas (como la tipología del inmueble, los usos de suelo catastrales y la división territorial municipal) en variables indicadoras binarias (dummies) mediante model.matrix(). Este procedimiento se aplicó de manera independiente a las matrices de entrenamiento, validación y prueba (reserva). Todas las covariables cuantitativas se estandarizaron internamente mediante la función cv.glmnet(), garantizando que la regularización actúe por igual sobre todas las variables independientemente de su escala de origen.

La selección de hiperparámetros se centró en el parámetro de regularización $\lambda$, que controla la severidad de la penalización sobre la complejidad del modelo. Para ello, se evaluó un conjunto de 100 valores candidatos de $\lambda$, generados automáticamente por el algoritmo. La búsqueda del hiperparámetro óptimo se realizó mediante validación cruzada de 10 pliegues (*10-fold Cross-Validation*) sobre los datos de entrenamiento, seleccionando finalmente el valor de $\lambda$ que minimizó el error cuadrático medio de validación cruzada ($\lambda_{\text{mín}}$).

La selección de hiperparámetros se centró en el parámetro de regularización $\lambda$, que controla la penalización sobre la complejidad del modelo. Se evaluaron 100 valores candidatos mediante validación cruzada de 10 pliegues (*10-fold Cross-Validation*), seleccionando finalmente $\lambda_{\text{mín}} = 0{,}00109$, correspondiente al valor que minimizó el error cuadrático medio de validación cruzada. Como resultado del proceso de selección de variables, se eliminaron `nombre_lots_max` y `has_terreno_unspecified`. La siguiente tabla muestra los coeficientes de las variables seleccionadas por Lasso.

Cuadro 1: Coeficientes estimados del modelo regularizado

| **Variable** | **Coeficiente** |
|---|---|
| Intercepto | 25.423970 |
| `type_localMaison` | 0.172802 |
| `surface_habitable` | 0.010251 |
| `piezas_max` | 0.005101 |
| `n_dependances` | 0.055620 |
| `surface_terrain_total` | $3{,}192663 \times 10^{-7}$ |
| `n_parcelles` | 0.003036 |
| `has_jardin` | -0.162255 |
| `has_sol` | 0.005712 |
| `has_pres` | -0.118043 |
| `has_terres` | -0.006058 |
| `has_verger` | 0.192425 |
| `latitude` | -0.394934 |
| `longitude` | 0.876228 |

## 5.3. Modelo Aditivo Generalizado (GAM)

Para capturar relaciones no lineales en el precio de los inmuebles sin perder la interpretabilidad del modelo, se especificó un Modelo Aditivo Generalizado (GAM) como el segundo procedimiento de aprendizaje ($M_2$). A diferencia de los modelos lineales tradicionales, un GAM reemplaza las pendientes fijas de las variables continuas por funciones curvas suaves (splines), permitiendo que la predicción se amolde a la forma real de los datos.

Para capturar que el precio no crece de forma estrictamente lineal con la dimensión de la propiedad (rendimientos decrecientes), se aplicaron splines de suavizado con base $k = 10$ a las variables continuas de superficie: `(surface_habitable, k=10)` y `(surface_terrain_total, k=10)`. Por su parte, el tipo de propiedad `(type_local)`, la estructura física `(piezas_max,n_dependances,n_parcelles,nombre_lots_max)`, los indicadores de terreno `(has_jardin,has_sol, etc.)` y las coordenadas geográficas `(latitude y longitude)` se incorporaron como términos estrictamente lineales para controlar las características base y la localización espacial.

El Modelo Aditivo Generalizado (GAM) ofrece una combinación óptima entre estabilidad e interpretabilidad simple. Por un lado, controla la varianza del modelo mediante una penalización sobre la curvatura de los splines (method = REML"), evitando que el ajuste persiga el ruido aleatorio del entrenamiento y sufra sobreajuste.
La inspección de los efectos parciales del modelo GAM (**plot(modelo_gam)**) confirma la presencia de no linealidades significativas en la superficie habitable, con un grado de libertad efectivo de edf = 8,14. La curva muestra una fuerte pendiente positiva en el rango de 0 a 200 $m^2$, evidenciando que el valor unitario por metro cuadrado es más alto en propiedades pequeñas y medianas. Para superficies superiores a los 400 $m^2$, el efecto muestra rendimientos decrecientes y una mayor banda de incertidumbre debido a la menor cantidad de transacciones de gran tamaño. Por su parte, la superficie del terreno presentó una forma cercana a la linealidad (edf = 1,62), reflejando una contribución marginal menor sobre el valor total de la transacción.

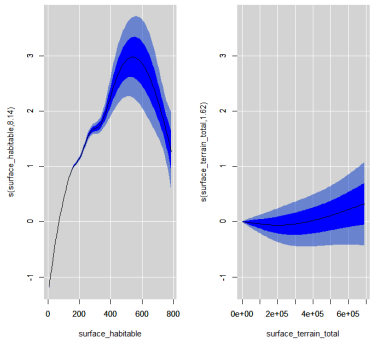



Figura 4: Efectos parciales centrados de la superficie habitable y del terreno en el modelo GAM ($M_2$)

## 5.4. XGBoost

Como representante de los métodos de ensamble basados en árboles de decisión, se implementó XGBoost (Extreme Gradient Boosting). Su inclusión responde a la necesidad de evaluar un modelo de alto rendimiento capaz de capturar interacciones no lineales de alto orden y patrones espaciales/físicos complejos sin asumir supuestos de linealidad ni aditividad. El método construye árboles de decisión de manera secuencial, donde cada nuevo árbol se ajusta para corregir los residuos de las iteraciones previas mediante la optimización de un gradiente descendente sobre la función de pérdida.

Para optimizar computacionalmente el algoritmo mediante la librería `xgboost` de R, las matrices de diseño correspondientes a los conjuntos de entrenamiento, validación y prueba ($X_{\text{train}}$, $X_{\text{val}}$ y $X_{\text{test}}$), previamente transformadas mediante codificación *dummy*, fueron convertidas a objetos de tipo `xgb.DMatrix`, cuya estruc-

tura permite optimizar el almacenamiento de los datos y agilizar las operaciones de entrenamiento y partición de nodos. Por otra parte, se mantuvo la variable respuesta en escala logarítmica (`log_valeur_fonciere`), configurando la función objetivo del algoritmo como una regresión con minimización del error cuadrático
Con el objetivo de identificar los atributos que tienen mayor relevancia en las predicciones del modelo XGBoost, se examinó la importancia relativa de las variables utilizadas durante el entrenamiento. Los resultados se presentan en la Figura 5.

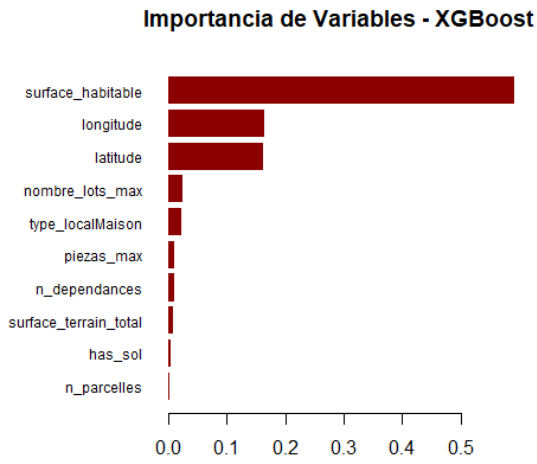



Figura 5: Importancia relativa de las variables en el modelo XGBoost.

Se observa que `surface_habitable` concentra la mayor importancia predictiva, seguida por las coordenadas geográficas `longitude` y `latitude`. En contraste, el resto de las variables presenta una contribución considerablemente menor, lo que evidencia el predominio de la superficie habitable y la ubicación espacial en las predicciones del modelo.

# 6. Resultados

## 6.1. Desempeño predictivo general de los modelos

Para comparar el desempeño predictivo de los modelos, se presentan las métricas obtenidas sobre los conjuntos de validación y prueba. Se consideran el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y la mediana del error absoluto, todas expresadas en euros, lo que permite evaluar tanto la magnitud promedio de los errores como su distribución.

Cuadro 2: Desempeño de los modelos en los conjuntos de validación y prueba

| | **Validación** | | | **Prueba** | | |
|---|---|---|---|---|---|---|
| **Modelo** | **MAE** | **RMSE** | **Mediana AE** | **MAE** | **RMSE** | **Mediana AE** |
| Baseline | 120423.45 | 192213.34 | 81369.00 | 113810.38 | 173725.99 | 81369.00 |
| LASSO | 96600.41 | 395425.74 | 60795.68 | 84427.64 | 199920.25 | 57708.64 |
| GAM | 68230.00 | 116755.43 | 43801.76 | 64158.20 | 106709.05 | 42277.39 |
| XGBoost | 54379.00 | 93210.94 | 32209.83 | 53237.81 | 94363.37 | 31966.87 |

Nota: MAE, RMSE y Mediana AE se expresan en euros (EUR).

Es posible notar que XGBoost presenta el mejor desempeño predictivo en ambos conjuntos, alcanzando los

menores valores de MAE, RMSE y mediana del error absoluto. GAM se posiciona como el segundo mejor modelo, mientras que LASSO presenta un RMSE considerablemente superior, lo que sugiere la presencia de algunas predicciones con errores de mayor magnitud. Asimismo, XGBoost mantiene resultados similares entre validación y prueba, lo que constituye una señal favorable de estabilidad y capacidad de generalización. En consecuencia, se identifica a XGBoost como el modelo de mejor desempeño global entre las alternativas evaluadas.

## 6.2. Análisis de errores según tipo de propiedad

Cuadro 3: Errores de predicción según tipo de vivienda en el conjunto de prueba

| Modelo | Tipo de vivienda | N° transacciones | MAE (EUR) | RMSE (EUR) |
|---|---|---|---|---|
| LASSO | Apartamento | 14.597 | 73.422 | 110.503 |
| LASSO | Casa | 4.121 | 140.761 | 371.870 |
| GAM | Apartamento | 14.597 | 53.863 | 82.734 |
| GAM | Casa | 4.121 | 100.625 | 165.756 |
| XGBoost | Apartamento | 14.597 | 42.684 | 70.425 |
| XGBoost | Casa | 4.121 | 90.619 | 151.251 |

Nota: MAE y RMSE se expresan en euros (EUR).

Al comparar por tipo de vivienda en el cuadro 3, predecir el precio de las casas resulta casi el doble de difícil que el de los apartamentos en todos los modelos. Esto ocurre porque las casas ($N$ = 4,121) son mucho más distintas entre sí (varían en terreno, jardín y dependencias) en comparación con la mayor homogeneidad de los apartamentos ($N$ = 14,597). Nuevamente, XGBoost ($M_3$) es el modelo más preciso en ambas categorías, logrando el error promedio más bajo tanto en apartamentos (42.684 €) como en casas (90.619 €).

## 6.3. Análisis de ventas de alto valor y localizaciones con pocos antecedentes

Con el propósito de evaluar el comportamiento de los modelos frente a propiedades de distinto nivel de precio, se realizó un análisis segmentando las transacciones según su valor. Para ello, se identificó el 5 % de las ventas de mayor precio (*Top 5 %*), comparándolo con el 95 % restante. Esta evaluación permite examinar si el desempeño predictivo se mantiene en operaciones de alto valor y determinar las diferencias en la magnitud de los errores entre ambos segmentos.

Cuadro 4: Desempeño de los modelos según categoría de precio en el conjunto de prueba

| Modelo | Categoría | N | Precio medio | MAE | RMSE | Mediana AE |
|---|---|---|---|---|---|---|
| LASSO | Normal (95 %) | 17.782 | 259.973 | 72.698 | 108.807 | 54.244 |
| LASSO | Top 5 % | 936 | 839.135 | 383.649 | 757.866 | 304.444 |
| GAM | Normal (95 %) | 17.782 | 259.973 | 55.302 | 78.060 | 40.293 |
| GAM | Top 5 % | 936 | 839.135 | 232.398 | 334.592 | 181.104 |
| XGBoost | Normal (95 %) | 17.782 | 259.973 | 46.040 | 70.144 | 30.358 |
| XGBoost | Top 5 % | 936 | 839.135 | 189.978 | 290.856 | 134.505 |

Nota: Los errores y los precios medios se expresan en euros (EUR).

Los resultados muestran un deterioro del desempeño predictivo en el segmento de alto valor para los tres modelos, reflejado en un aumento considerable de las métricas de error. No obstante, XGBoost mantiene el mejor desempeño en ambos segmentos, alcanzando un MAE de 189.978 EUR y un RMSE de 290.856 EUR en

el Top 5 %, valores inferiores a los obtenidos por GAM y LASSO. Esto evidencia que, aunque las propiedades de mayor valor representan un desafío predictivo considerable, XGBoost logra mantener una ventaja relativa frente a las demás alternativas evaluadas.

Adicionalmente, se analizó el desempeño de los modelos según la disponibilidad de antecedentes históricos de ventas en cada localización. Para ello, las observaciones se clasificaron en tres grupos: localizaciones con pocos antecedentes (10 o menos ventas), antecedentes medios (entre 11 y 50 ventas) y muchos antecedentes (más de 50 ventas). Esta segmentación permite examinar cómo varía la precisión predictiva en zonas con distintos niveles de información histórica disponible.

Cuadro 5: Desempeño de los modelos según disponibilidad de antecedentes históricos en el conjunto de prueba

| **Modelo** | **Disponibilidad de antecedentes** | **N** | **MAE (EUR)** | **RMSE (EUR)** |
|---|---|---|---|---|
| LASSO | Pocos ($\leq$ 10 ventas) | 115 | 102.267 | 162.851 |
| GAM | Pocos ($\leq$ 10 ventas) | 115 | 84.390 | 119.423 |
| XGBoost | Pocos ($\leq$ 10 ventas) | 115 | 74.106 | 116.294 |
| LASSO | Medios (11–50 ventas) | 1.067 | 99.339 | 186.803 |
| GAM | Medios (11–50 ventas) | 1.067 | 72.746 | 112.074 |
| XGBoost | Medios (11–50 ventas) | 1.067 | 67.473 | 105.667 |
| LASSO | Muchos ($>$ 50 ventas) | 17.536 | 87.481 | 200.910 |
| GAM | Muchos ($>$ 50 ventas) | 17.536 | 63.503 | 106.285 |
| XGBoost | Muchos ($>$ 50 ventas) | 17.536 | 52.235 | 93.470 |

Nota: N corresponde al número de transacciones evaluadas en cada categoría. Los errores se expresan en euros (EUR).

Los resultados muestran que XGBoost obtiene el menor MAE en las tres categorías, manteniendo su ventaja frente a GAM y LASSO independientemente de la disponibilidad de antecedentes históricos. Asimismo, se observa que los errores de XGBoost y GAM son mayores en las localizaciones con pocos antecedentes que en aquellas con más de 50 ventas, lo que sugiere que una menor disponibilidad de información histórica puede dificultar la estimación de precios. Por otra parte, LASSO presenta los mayores valores de RMSE en las tres categorías, destacando especialmente en las localizaciones con muchos antecedentes.

## 6.4. Análisis de sensibilidad y robustez de los modelos

Con el propósito de evaluar la estabilidad de las estimaciones frente a cambios en los supuestos de diseño, se realizaron dos análisis de sensibilidad (Cuadros 6 y 7):

Cuadro 6: Análisis de sensibilidad: escala de la variable respuesta

| | **Escala logarítmica** | | | **Escala original** | | |
|---|---|---|---|---|---|---|
| **Modelo** | **MAE** | **RMSE** | **Mediana AE** | **MAE** | **RMSE** | **Mediana AE** |
| LASSO | 84427.64 | 199920.25 | 57708.64 | 82862.52 | 126753.50 | 57168.55 |
| GAM | 64158.20 | 106709.05 | 42277.39 | 82816.69 | 126777.50 | 56821.79 |
| XGBoost | 53237.81 | 94363.37 | 31966.87 | 55045.38 | 96202.30 | 33694.47 |

Nota: Todas las métricas se expresan en euros (EUR). Los modelos incorporan las variables de latitud y longitud.

Se contrastó en el cuadro 6 el rendimiento de los modelos optimizados en escala logarítmica frente a aquellos ajustados directamente en su escala original. Los resultados confirman que la transformación logarítmica es clave para estabilizar la varianza y reducir el impacto de las colas pesadas de la distribución de precios, permitiendo que algoritmos como *XGBoost* alcancen el menor error absoluto mediano (31,966, 87 €).

Cuadro 7: Análisis de sensibilidad: incorporación de variables geográficas

| | Con latitud y longitud | | | Sin latitud y longitud | | |
|---|---|---|---|---|---|---|
| **Modelo** | **MAE** | **RMSE** | **Mediana AE** | **MAE** | **RMSE** | **Mediana AE** |
| LASSO | 84427.64 | 199920.25 | 57708.64 | 90705.85 | 188389.74 | 60084.30 |
| GAM | 64158.20 | 106709.05 | 42277.39 | 84636.83 | 132165.85 | 57521.09 |
| XGBoost | 53237.81 | 94363.37 | 31966.87 | 81139.81 | 129073.75 | 54057.22 |

Nota: Todas las métricas se expresan en euros (EUR). La variable respuesta se mantiene en escala logarítmica.

Se evaluó en el cuadro 7 el impacto de suprimir las coordenadas geográficas (*latitude* y *longitude*). La eliminación de estas variables genera un incremento drástico en el MAE de todos los modelos (por ejemplo, elevando el error de *XGBoost* en casi 28,000 €), lo que evidencia la alta dependencia del valor inmobiliario respecto a la localización territorial y valida la necesidad de incorporar la dimensión espacial de forma explícita.

## 6.5. Incertidumbre y limitaciones del análisis

A pesar del rigor metodológico aplicado en la depuración de los registros, la validación temporal y la implementación de los modelos predictivos (*Lasso*, *GAM* y *XGBoost*), los resultados obtenidos presentan diversas fuentes de incertidumbre y limitaciones estructurales que deben ser consideradas en su interpretación:

- **Calidad, completitud y filtrado de los registros:** El proceso de depuración requirió la exclusión de transacciones con superficies habitables menores a 8 $m^2$, precios por metro cuadrado inferiores a 1,000€/$m^2$, y la imputación de valores faltantes en coordenadas geográficas (mediante la mediana comunal) y número de habitaciones (mediante la media por tipo de vivienda). Estas decisiones, aunque necesarias para estabilizar la muestra, introducen un sesgo de selección y una fuente de incertidumbre sobre los registros extremos o mal codificados en la fuente original.

- **Incertidumbre en la predicción de inmuebles de alto valor (Top 5 %):** Como se evidenció en el análisis de segmentación de precios, los errores de predicción (tanto MAE como RMSE) aumentan de manera considerable en el tramo correspondiente al 5 % de las propiedades más costosas (precio medio superior a 839,135 €). La escasez relativa de transacciones en este segmento superior limita la capacidad de aprendizaje de los algoritmos, generando mayor incertidumbre y subestimaciones sistemáticas en propiedades de este valor.

- **Efecto de la densidad histórica a nivel local:** El desempeño predictivo exhibe una dependencia directa de la disponibilidad de antecedentes en el ámbito territorial. Las zonas geográficas o comunas con baja frecuencia de compraventas ($< 10$ ventas) registran errores de predicción superiores en comparación con los sectores consolidados de alta transaccionalidad, reflejando la dificultad de los modelos para generalizar en contextos con escasez de información local.

- **Limitaciones de la representación espacial y características omitidas:** Si bien se incorporaron las coordenadas geográficas (*latitude* y *longitude*) y variables de localización administrativa, el modelo carece de atributos urbanísticos cualitativos (por ejemplo: cercanía a estaciones de transporte, áreas verdes, calidad constructiva detallada o nivel socioeconómico del microentorno). Esto restringe la capacidad de capturar dinámicas hiperlocales que influyen en el valor inmobiliario.

## 6.6. Alcance e interpretación de los resultados

El objetivo de este trabajo es predecir el valor de una propiedad a partir de diversas características físicas y geográficas. En este contexto, el interés principal se centra en la capacidad predictiva de los modelos, por lo

que su evaluación se realiza mediante métricas como el MAE, el RMSE, entre otras. Esto se diferencia de un enfoque causal, cuyo propósito es identificar si una determinada característica genera cambios en el precio de una propiedad y cuantificar el efecto que produce. En consecuencia, la importancia asignada a las variables por los modelos permite reconocer cuáles contribuyen en mayor medida a la predicción, pero no implica que estas características provoquen cambios en el valor de las propiedades. Por lo tanto, los resultados deben interpretarse desde una perspectiva estrictamente predictiva y no como evidencia de relaciones causales.

# 7. Discusión y conclusión

Los resultados muestran que *XGBoost* presenta el mejor desempeño predictivo entre los tres modelos evaluados, superando a GAM y *Lasso* tanto en validación como en prueba. Esto sugiere que su capacidad para capturar relaciones no lineales e interacciones permite representar de mejor manera la complejidad del mercado inmobiliario. Asimismo, se identifica que la superficie habitable y la ubicación geográfica son los principales atributos asociados a la capacidad predictiva. Sin embargo, se observan mayores errores en viviendas de alto valor, casas y localidades con pocos antecedentes de compraventa, lo que evidencia dificultades para generalizar en segmentos con mayor heterogeneidad o menor disponibilidad de información. Además, la ausencia de variables relacionadas con la calidad constructiva y las características del entorno constituye una limitación para mejorar las estimaciones.

En conclusión, se cumple el objetivo de comparar distintos enfoques para predecir el valor de las transacciones inmobiliarias residenciales en el departamento de Rhône, identificando a *XGBoost* como la alternativa de mejor desempeño, con un MAE de 53,237, 81 € en el conjunto de prueba. Los análisis también confirman la importancia de incorporar información geográfica y características físicas de las propiedades para obtener predicciones más precisas. No obstante, los resultados deben interpretarse considerando las limitaciones de los datos y la mayor incertidumbre en determinados segmentos del mercado. Finalmente, futuras investigaciones podrían incorporar nuevas variables territoriales y urbanísticas que permitan mejorar la capacidad predictiva y obtener estimaciones más representativas del mercado inmobiliario.

# 8. Reproducibilidad y contribuciones

## 8.1. Entorno, entradas y ejecución

El análisis completo fue desarrollado en el lenguaje R. Para garantizar la reproducibilidad del estudio desde una copia limpia, todo el flujo de trabajo que incluye desde la depuración de datos hasta el ajuste de modelos y la generación de métricas, se consolidó en un único script.

- **Comando de ejecución:** El análisis se reproduce ejecutando el siguiente comando en la terminal desde el directorio raíz del proyecto: `analisis.R`
- **Versión del repositorio:** El código fuente, historial de versiones y el documento final se encuentran alojados en el repositorio público de GitHub: https://github.com/franciscaseplveda-svg/trabajo_final_eyp3407
- **Entradas:** La ejecución requiere disponer del archivo comprimido original `caso09_dvf_rhone.zip` ubicado en la carpeta datos/. Este archivo contiene los registros de la base *Demandes de valeurs foncières géolocalisées* para el departamento 69 entre los años 2021 y 2023.
- **Tiempo de ejecución y recursos:** La ejecución completa del script `analisis.R` toma aproximadamente entre 4 y 5 minutos utilizando un equipo estándar.

## 8.2. Síntesis de los aportes

El desarrollo del proyecto se estructuró de forma colaborativa, aportando todos en cada una de las etapas del flujo del trabajo. Tareas que :

- **Francisca Sepúlveda:** Lideró el diseño metodológico general del estudio y la redacción del marco introductorio, además de colaborar en la definición y validación de las métricas de evaluación fuera del ajuste.
- **Alexander Pinto:** Estuvo a cargo de la exploración, depuración y limpieza masiva de la base de datos DVF (reconstrucción de la unidad transacción, tratamiento de valores faltantes y exclusión de registros inconsistentes).
- **Karina Armijo:** Lideró la creación e implementación computacional de los tres modelos predictivos (LASSO, GAM y XGBoost) utilizando los conjuntos de entrenamiento y validación.
- **Pía Mella:** Se encargó de la medición de desempeño en el conjunto de reserva (2023), la elaboración de los análisis de errores, sensibilidad y heterogeneidad espacial, y la consolidación técnica del informe en LaTeX.

## 8.3. Declaración de uso de Inteligencia Artificial

- **Propósito y partes afectadas:** La herramienta fue utilizada como apoyo para la depuración de código en R, así como para sugerir mejoras en la redacción técnica del informe .
- **Comprobación:** Todos los bloques de código sugeridos fueron ejecutados, validados matemáticamente y contrastados con la documentación oficial de los paquetes de R.

## 8.4. Referencias


- Direction Générale des Finances Publiques (DGFiP) y Etalab. (2026, 7 de noviembre). *Demandes de valeurs foncières géolocalisées (DVF)*. https://www.data.gouv.fr/datasets/demandes-de-valeurs-foncieres-geolocalisees

# 9. Anexo

## 9.1. Definición de las variables creadas

### 1. Identificación, Ubicación y Registro

- **`id_mutation`**
  - **Variable(s) original(es):** `id_mutation`
  - **Significado:** Identificador único y alfanumérico de la transacción o acto notarial de compraventa. Es la clave primaria sobre la cual se consolidó toda la base a nivel de 1 fila por transacción.
- **`date_mutation`**
  - **Variable(s) original(es):** `date_mutation`
  - **Significado:** Fecha oficial en que se registró la transferencia del inmueble.
- **`numero_disposition`**
  - **Variable(s) original(es):** `numero_disposition`
  - **Significado:** Número de orden del acto administrativo o disposición dentro del documento de venta.
- **`nature_mutation`**
  - **Variable(s) original(es):** `nature_mutation`
  - **Significado:** Tipo de transacción realizada (ej. Venta, Venta en estado futuro de terminación, Adjudicación).
- **`code_postal`** / **`code_commune`** / **`nom_commune`** / **`code_departement`**
  - **Variable(s) original(es):** `code_postal`, `code_commune`, `nom_commune`, `code_departement`
  - **Significado:** Variables de localización político-administrativa que ubican la propiedad en Francia a nivel de departamento, comuna y código postal.

### 2. Variable Respuesta ($Y$)

- **`valeur_fonciere`**
  - **Variable(s) original(es):** `valeur_fonciere`
  - **Significado:** Precio total de la transacción inmobiliaria expresado en euros (€). Es la variable dependiente $Y$ del modelo.

### 3. Características de la Vivienda y Edificación

- **`type_local`**
  - **Variable(s) original(es):** `type_local` y `code_type_local` de la residencia principal.
  - **Significado:** Clasificación cualitativa del tipo de edificación principal de la compraventa (Maison / Appartement).
- **`piezas_max`**
  - **Variable(s) original(es):** `nombre_pieces_principales` y `code_type_local`

- **Significado:** Número máximo de habitaciones/piezas principales observado entre los edificios habitacionales de la transacción.

- **piezas_sum**
  - **Variable(s) original(es):** `nombre_pieces_principales` y `code_type_local`
  - **Significado:** Suma acumulada total de habitaciones principales involucradas en la transacción (útil cuando la venta incluye más de una vivienda).

- **surface_habitable**
  - **Variable(s) original(es):** `surface_reelle_bati` y `code_type_local`
  - **Significado:** Superficie real construida ($m^2$) exclusiva de la edificación principal (casa o departamento). Corresponde al valor exacto de `surface_reelle_bati` filtrado para bienes residenciales.

## 4. Anexos y Copropiedad

- **n_dependances**
  - **Variable(s) original(es):** `code_type_local`
  - **Significado:** Conteo total de estructuras secundarias o anexos no habitacionales (estacionamientos cerrados, garages, bodegas/cavas) incluidos en la venta.

- **nombre_lots_max**
  - **Variable(s) original(es):** `nombre_lots`
  - **Significado:** Cantidad máxima declarada de lotes de copropiedad (*lots de copropriété*) en la transacción. Mide la magnitud de la propiedad bajo régimen de copropiedad horizontal.

- **nombre_lots_sum**
  - **Variable(s) original(es):** `nombre_lots`
  - **Significado:** Suma total acumulada de lotes de copropiedad transferidos en la venta a través de todas sus unidades catastrales.

## 5. Terrenos y Parcelas

- **n_terrenos**
  - **Variable(s) original(es):** `code_type_local`
  - **Significado:** Cantidad de parcelas de terreno sin edificación construida vinculadas a la transacción.

- **surface_terrain_total**
  - **Variable(s) original(es):** `surface_terrain` y `code_type_local`
  - **Significado:** Superficie total de suelo/terreno no construido ($m^2$) transferido en la transacción.

- **n_parcelles**
  - **Variable(s) original(es):** `id_parcelle`
  - **Significado:** Conteo de identificadores catastrales de parcela únicos involucrados en el acto de venta.

- **Variables Dummies de Cultivo (`has_jardin`, `has_sol`, `has_pres`, `has_terres`, `has_verger`)**

- **Variable(s) original(es):** `nature_culture`
- **Significado:** Indicadores binarios (1/0) que señalan si el terreno incluye tipos específicos de uso o cobertura de suelo (jardines, suelos/patios, prados, tierras agrícolas o huertos).

- **`has_terreno_unspecified`**
  - **Variable(s) original(es):** `n_terrenos` y las dummies de cultivo anteriores.
  - **Significado:** Variable indicadora que toma valor 1 cuando la compraventa incluye parcelas de terreno, pero la variable *nature_ culture* venía sin clasificar en el registro catastral.

## 6. Demográficas y Geográficas

- **`latitude`** / **`longitude`**
  - **Variable(s) original(es):** `latitude`, `longitude`
  - **Significado:** Coordenadas geográficas espaciales que georreferencian la ubicación exacta del inmueble transado dentro del departamento de Rhône.